01 — Scientific Findings (DataMate, Zalo AI Challenge 2026)

Cập nhật 2026-10-31 04:45 UTC (hết khung chat 2). Branch `claude/peaceful-carson-0dny90`, repo `lhaochen118-ship-it/ZC`. Tài liệu này chỉ nêu đóng góp, kết quả và bằng chứng; cách vận hành ở PDF 2, việc tiếp theo ở PDF 3.

1. Bài toán và hệ quả của thước đo

- **Bài toán:** agent trả lời câu hỏi tiếng Việt đời thường trên dữ liệu bảng bẩn (CSV/Excel/SQLite) của hộ kinh doanh nhỏ, hoặc trả `unanswerable` / `abstain`.
- **Thước đo:** Penalized Accuracy (đúng +1, abstain 0, sai −1).
- **Hệ quả quyết định:** chỉ trả lời khi xác suất đúng ước lượng > 0.5. Ước lượng dùng **tỷ lệ phiếu** của K chương trình độc lập: conf = phiếu của đáp án đứng đầu / K, trả lời khi conf ≥ τ.
- **Dữ liệu:**
- train 3000 câu / 30 DN (có đáp án); public 1000 câu / 14 DN.
- Câu hỏi theo khuôn mẫu: doanh thu theo kỳ, % thay đổi, tỉ lệ huỷ, top-k bán chạy, khách, công nợ, kho, giá nhập…
- Văn phong chat: viết tắt (`hqua`, `dthu`, `bnhiu`), không dấu, gõ telex sai (`tieenf`, `dduwowcj`).
- **Rulebook khác nhau giữa các split** (public thêm luật mới; private có ngành mới) → không hard-code luật; agent đọc rulebook lúc chạy.

2. Giao thức đánh giá (cố định)

- **Chia theo DN:**
- chọn mọi cấu hình / ngưỡng trên **dev** = biz_101–120;
- báo cáo trên **holdout** = biz_121–130.
- **So sánh cặp:** mọi so sánh giữa hai cấu hình làm trên **cùng tập DN và cùng câu hỏi**.
- **Công cụ:**
- bộ chấm `src/score.py` theo đúng luật khớp của BTC (kiểm: chấm đáp án chuẩn với chính nó = 1.0);
- `src/compare.py`: PA dev/holdout, τ chọn trên dev, vote lại offline;
- `src/analyze.py`: hiệu chuẩn, loại lỗi.
- **Few-shot leave-business-out:** ví dụ truy hồi luôn lấy từ DN khác (không bao giờ cùng DN với câu đang chấm). Lúc thi mọi DN đều mới, nên đây là ước lượng trung thực.

3. Đóng góp đã kiểm chứng

3.1 Bộ làm sạch tổng quát (`src/ingest.py`, từ khung chat 1)

- **Header và dòng rác:** dò header theo mật độ ô chữ; bỏ dòng tiêu đề, header lặp, dòng tổng; ghép header 2 tầng.
- **Số kiểu Việt / Mỹ:** `10.000đ`, `105k`, `1tr440`, `1,134tr`, `531 500`, `(1.000)`, `12,5%`, `1 bao 25kg`. Dấu thập phân suy theo cột.
- **Ngày nhiều dạng:** ISO, `dd/mm/yyyy`, `1 thg 6 2025`, `Ngày 1 tháng 6 năm 2025`, serial Excel; ngày không ghi năm lấy năm từ tên sheet / file.
- **Mã:** giữ dạng chữ (số 0 đầu, IMEI…).
- **Gộp:** gộp các file / sheet của cùng một danh sách.

Bằng chứng: - `tests/test_ingest_robust.py`: 12/12 biến thể bẩn tổng hợp (không lấy từ dữ liệu thi). - Audit cột đọc được một phần: 78 → 0 trên 44 DN. - Chương trình viết tay trên bảng sạch khớp tuyệt đối đáp án BTC.

3.2 Lớp ngữ nghĩa có kiểm thử: `src/semantic.py: build_sales` (mới)

Ý tưởng: tách **luật ghi chép chung** của rulebook ra code Python đã kiểm thử; LLM chỉ còn **ánh xạ cột** (việc mô hình 14B làm tốt), thay vì tự viết lại các luật đó trong từng chương trình (việc nó làm sai một cách hệ thống).

Luật được cài sẵn: - ô trống ở dòng sau của đơn kế thừa dòng đầu; - dòng trùng hệt trong cùng đơn tính một lần; dòng trùng ở hai đơn, hoặc ở bảng không có mã đơn, tính cả hai; - mỗi đơn đúng một trạng thái (có dòng trả → trả hàng; có dòng huỷ → huỷ); - `valid` = không huỷ và không trả; - doanh thu = tổng thành tiền dòng; - khách lẻ / vãng lai / trống → không phải khách; - quy đổi đơn vị theo bảng quy đổi (`conv=`).

Chịu lỗi của LLM (đều tổng quát, không theo DN): - tự tìm bảng header của đơn khi bị quên hoặc truyền nhầm (chọn bảng có cột cần và khoá trùng mã đơn > 50 %); - tự đổi chỗ khi truyền nhầm bảng dòng / bảng đơn; - giữ cả cột gốc và cột chuẩn; - báo nhãn trạng thái chưa ánh xạ.

Bằng chứng: cho đáp án doanh thu tháng khớp BTC trên 4 kiểu tổ chức: phẳng có mã đơn (biz_101), phẳng không mã đơn (biz_113), header + chi tiết có giờ (biz_106, biz_124), SQLite nhiều bảng (biz_123).

3.3 Chuẩn hoá câu hỏi và entity linking (`src/vnnorm.py`, `agent.EntityIndex`, mới)

- `vnnorm`**:** mở rộng viết tắt chat theo nguyên từ (`hqua` → hôm qua, `th7/2025` → tháng 7/2025, `dthu`, `bnhiu`, `đc`...). Giải mã gõ telex sai chỉ khi kết quả là từ có trong từ vựng (rulebook + câu hỏi của split). Bản chuẩn hoá hiển thị **cạnh** câu gốc, câu gốc vẫn là chuẩn.
- **Entity linking:** liệt kê các giá trị chữ của DN (tên hàng / khách / nhóm...) có dạng bỏ dấu nằm trong câu hỏi bỏ dấu, kèm cách viết đúng và cột chứa nó (`noi lau ga la e` → 'Lẩu gà lá é' trong cột 'Hàng bán' của bảng ban_hang).
- **Khoảng ngày dữ liệu:** in khoảng ngày có dữ liệu của DN, để câu về kỳ nằm ngoài dữ liệu trả `unanswerable` (luật §7). **Chưa đo.**

3.4 Few-shot truy hồi chương trình đúng (`--shots`, `src/build_shots.py`, mới) — đòn bẩy lớn nhất

- **Xây thư viện:** từ các run trên train, giữ mỗi (câu hỏi, nhánh) một chương trình mà đáp án thực thi **đúng** theo bộ chấm (ngắn nhất).
- **Truy hồi:** mỗi câu mới lấy 2 ví dụ gần nhất của DN khác, theo TF-IDF từ + bigram (bỏ dấu, số → 0), theo đúng nhánh:
- nhánh A: chương trình trên bảng chuẩn C — tên cột giống nhau ở mọi DN nên chuyển giao trực tiếp;
- nhánh B: chương trình trên bảng thô T.
- **Thư viện v4:** 4228 chương trình, phủ 2446/3000 câu train (`src/shots/train_shots.jsonl`). Chỉ dùng train (luật 6).

4. Kết quả thực nghiệm

Qwen3-14B-AWQ, K = 4 mẫu (AABB: 2 trên C, 2 trên T; mẫu đầu mỗi nhánh greedy), 2 vòng sửa lỗi, tự kiểm tra khi kết quả 0 / rỗng, 4×L4 DP.

4.1 Tiến trình (mỗi dòng so trên cùng DN với dòng trên)

Cấu hình	Tập	PA dev	PA holdout	top-answer đúng
Path B thuần, code khung chat 1 (smoke)	30 câu	−0.40		4/4 phiếu chỉ đúng 40 %
+ `build_sales` + compile rút gọn (orders + lines)	2251 câu / 22 DN	+0.19 (τ 0.75)	+0.10	1004/2251
+ norm-q, khách lẻ, `conv`, auto-header (e5)	474 câu	+0.36		293/474
+ **shots** (e6a, cùng code, cùng kết quả compile)	474 câu	**+0.58**		**370/474**
Cấu hình tốt nhất, toàn bộ train (hợp e6a, e7, e7b, e8, e9)	**3000 câu**	**+0.471**	**+0.437**	**2130/3000 (71 %)**

4.2 Theo type (cấu hình tốt nhất, 3000 câu)

Type	PA
number	+0.48
percent	+0.50
date	+0.65
string	+0.53
boolean	+0.83
list	+0.22
table	−0.16
unanswerable	**−0.29**

4.3 Kết quả phụ

- **Compile + 2 nhánh tốt hơn chỉ bảng thô:** trên cùng 1502 câu, AABB dev +0.22 vs BBBB +0.17; top-answer đúng 729 vs 663.
- **Độ bền compile:**
- Bản cũ (khung chat 1): 5/40 ứng viên.
- Với helper và các sửa lỗi: e9 compile được 10/11 DN; e7b 5/5; e8 6/6.
- Lỗi compile là nguồn biến thiên lớn nhất giữa các run: một DN compile hỏng mất phần lớn lợi ích của DN đó.
- **Hiệu chuẩn** (e3h, 2251 câu, độ đúng của đáp án đứng đầu theo tỷ lệ phiếu):

Tỷ lệ phiếu	1/4	2/4	3/4	4/4
Độ đúng	24 %	40 %	62 %	80 %

Với shots, độ đồng thuận và độ đúng cùng tăng; τ = 0.5 tốt nhất (holdout +0.437 vs +0.426 ở τ 0.75). - **Thinking (Qwen3 `--think`), chỉ trên T4, không shots:** - Độ đúng từng mẫu: dev 77/130 vs 52/130 không think; holdout 26/60 vs 20/60. - Nhưng vẫn thấp hơn cấu hình có shots không think (45 % vs 51 % từng mẫu trên 60 câu holdout trùng). - **Cộng dồn think + shots có lợi:** e10l (L4, 316 câu, cùng câu với e7) PA dev +0.69 vs +0.59, holdout +0.90 vs +0.70, top-answer 272 vs 253; e10 (T4, 40 câu) từng mẫu 84 % vs 69 %. Chậm ≈ 2.5× (~47 s/câu/L4). e10l cũng có code / shots mới hơn e7 nên chênh lệch không hoàn toàn do thinking. Holdout nhỏ (e10b, T4, 40 câu) cho +0.00 vs +0.30, nhưng **phép thử quyết định e11 (L4, 354 câu holdout, cùng câu với e8): PA +0.514 vs +0.254** (number +0.57 vs +0.25, percent +0.50 vs +0.24, unanswerable 9/9 đúng). e11 khác e8 cả ở code (khoảng ngày dữ liệu, SafePool) và shots (v4 vs v2) → +0.26 là của cả gói; phần riêng của thinking chưa tách.

5. Kết quả âm / trung tính (đã loại, có lý do)

Thử	Kết quả	Quyết định
Ngưỡng τ riêng theo type, chọn trên dev	holdout 0.096 vs 0.101 (τ chung)	dùng τ chung
Trọng số phiếu nhánh A > B (0.5–3)	dev không đổi (+0.187), holdout dao động trong nhiễu	phiếu đều
Chỉ bảng thô (BBBB)	kém AABB (mục 4.3)	giữ compile
Compile đầy đủ (items / purchases / payments)	5/40 (khung chat 1); smoke 2 h chưa xong 30 câu	dùng `--compile-scope sales`
norm-q + khách lẻ + conv riêng lẻ (e4)	top-answer bằng e3h (172/316) vì biz_116 compile hỏng ở e4	giữ (có ích khi compile được), sửa compile

6. Lỗi còn lại (từ e7 / e8 / e9, theo tần suất)

1. `unanswerable` **sai** (70 câu đáp án unanswerable, chỉ 22 đúng): - kỳ nằm ngoài dữ liệu → trả 0; - thông tin không được ghi (kênh COD, ví điện tử, địa chỉ đường, "giao trễ") → trả 0; - ngược lại, 34 lần trả unanswerable sai, chủ yếu câu **giá nhập bình quân** (purchases không có trong C, NOTES của compile nói "không có dữ liệu nhập"); - đã sửa (khoảng ngày dữ liệu, NOTES không được gọi bảng T là thiếu) nhưng **chưa đo**.
2. **Xếp hạng bán chạy sai** khi `qty_base` quy đổi sai (đơn vị m / bao / viên trộn lẫn).

3. **Kỳ tương đối:** "tuần rồi", "tuần này", ca sáng / chiều (thiếu `time=` trong compile; đã thêm gợi ý, chưa đo).
4. **Câu nghiệp vụ hiếm:** - đếm "mặt hàng ế"; - tồn kho theo đơn vị lớn [chẵn, lẻ]; - hiệu ứng tăng giá; - đợt giao (đã cải thiện nhờ shots).

7. Hạn chế và điều kiện kiểm chứng

- **Chưa có điểm public LB.** Run public `p1` (cấu hình tốt nhất, 1000 câu) đang chạy lúc bàn giao (nghi kẹt).
- **Thinking:** gói code mới nhất + shots v4 + thinking có lợi rõ trên holdout (e11: +0.51 vs +0.25, 354 câu); phần riêng của thinking chưa tách. Thời gian 52–98 s / câu / L4 → sát giới hạn 6 giờ nếu private ~2000 câu.
- **Holdout chỉ 10 DN, 1024 câu.** Khác biệt < ~0.03 PA giữa hai cấu hình là trong nhiễu. Các run khác nhau dùng thư viện shots v1–v3 (lớn dần) và code tăng dần, nên số "toàn train" là **hợp nhiều run**, không phải một run duy nhất.
- **Bộ làm sạch và prompt được phát triển khi nhìn train + public.** Bằng chứng độc lập cho dữ liệu chưa thấy chỉ có:
- bộ test tổng hợp;
- giao thức leave-business-out.

Private test có ngành mới, nên luật ngành mới phải được đọc từ rulebook. - **Chưa đo trên phần cứng chấm:** - tất định ($|\Delta PA| \leq 0.03$); - thời gian trên 2×RTX 5090; - mô hình FP8 (L4 chỉ chạy AWQ).