01 — Scientific Findings (DataMate, Zalo AI Challenge 2026)

Bàn giao ngày 2026-10-30 (branch `datamate`, repo `lhaochen118-ship-it/ZC`). Tài liệu này nêu đóng góp, ý nghĩa, kết quả tích cực và tiêu cực, bằng chứng và điều kiện kiểm chứng. Điểm PA duy nhất đo được: −0.14 trên 150 câu train (E2b, code cũ), xem §3.

1. Bài toán và hệ quả của thước đo

- Agent trả lời câu hỏi tiếng Việt đời thường trên dữ liệu bảng bẩn (CSV/Excel/SQLite) của hộ kinh doanh nhỏ, hoặc trả `unanswerable` / `abstain`. Điểm là **Penalized Accuracy**: đúng +1, abstain 0, sai −1.
- **Hệ quả quyết định:** trả lời khi và chỉ khi xác suất đúng ước lượng > 0.5. Mọi thiết kế phải có ước lượng xác suất đúng có hiệu chuẩn; hiện dùng **tỷ lệ phiếu** của K chương trình độc lập làm ước lượng.
- Train 3,000 câu / 30 DN (có đáp án), public 1,000 / 14 DN. Train: number 63 %, percent 19 %, list 6 %, date 5 %, string 3 %, unanswerable 2.3 %, boolean, table < 1 %. Khoảng 40 % câu là doanh thu.
- **Rulebook khác nhau giữa các split** (public thêm định nghĩa mới), private test có ngành mới → hệ thống phải đọc rulebook và README lúc chạy; không thể mã hoá cứng luật của train.

2. Đóng góp đã kiểm chứng

2.1 Bộ làm sạch tổng quát (`src/ingest.py`)

Chỉ dựa trên quy ước chung, không theo tên DN / cột / file cụ thể:

- dò dòng header (mật độ ô chữ), bỏ header lặp và dòng "Tổng…/Ghi chú…";
- ghép header 2 tầng có tên con trùng;
- số kiểu Việt và kiểu Mỹ: `10.000đ`, `105k`, `1tr440`, `1,134tr`, `531 500`, `VND 1,234`, `(1.000)`, `12,5%`, `1 bao 25kg` (giá trị + cột đơn vị `__unit`);
- quy ước dấu thập phân suy theo **từng cột**, chỉ dùng cho giá trị mơ hồ kiểu `1.500`; cột tiền giữ quy tắc theo từng giá trị;
- ngày: `dd/mm/yyyy`, ISO, `1 thg 6 2025`, `Ngày 1 tháng 6 năm 2025`, serial Excel (cả dạng chuỗi trong cột ngày), `dd/mm` + năm lấy từ tên sheet / file / dòng tiêu đề;
- mã (số 0 đầu, IMEI, ≥ 12 chữ số) và địa chỉ giữ dạng chữ;
- gộp các file / sheet của cùng một danh sách.

Bằng chứng	Kết quả
Audit "cột chỉ đọc được một phần" trên dữ liệu thật	78 → **0** (train); public còn 2 cột IMEI, đúng là chữ
Bộ test tổng hợp `tests/test_ingest_robust.py`: 12 biến thể bẩn không lấy từ dữ liệu thi	**12/12** khôi phục đúng giá trị
So từng giá trị giữa 2 phiên bản cache trên 44 DN	phát hiện lỗi `1,134tr` → **1,134 tỷ** (đúng: 1.134 triệu) ở 13 DN; sau sửa chỉ còn đúng các thay đổi mong muốn
3 chương trình viết tay trên bảng đã làm sạch (`biz_101`)	**khớp tuyệt đối** đáp án BTC (số đơn hôm qua, doanh thu hôm nay, ngày doanh thu cao nhất tháng)

Ý nghĩa: lớp dữ liệu đủ để ra đáp án chính xác tuyệt đối; sai số còn lại nằm ở bước sinh chương trình.

2.2 Bộ chấm cục bộ đúng luật BTC (`src/score.py`)

Chuẩn hoá chuỗi (NFC, lowercase, bỏ dấu câu, giữ dấu tiếng Việt), alias theo phần tử / theo dòng, list có thứ tự, table so cột theo tên rồi theo vị trí, hàng như tập hợp, số phải là JSON number.

- Chấm đáp án chuẩn với chính nó: PA = 1.0 (3000/3000).
- 167/167 câu trả lời bằng alias / mã được chấm đúng.
- Số ghi dạng chuỗi bị chấm sai, đúng rulebook §9.

2.3 Kiến trúc agent (`src/agent.py`), mới kiểm chứng ở mức đường ống

1. **Compile** (một lần mỗi DN): LLM viết chương trình dựng bảng chuẩn `C` (orders / lines / items / purchases / payments + NOTES về thông tin không có). Kiểm tra schema; lỗi được gửi lại để sửa. Chọn ứng viên có chữ ký tháng đồng thuận nhất.

2. **Answer**: K chương trình mỗi câu chia hai nhánh (A dùng `C`, B dùng bảng làm sạch `T`); sửa lỗi theo traceback; tự kiểm tra khi kết quả 0 / rỗng.
3. **Vote** theo đúng luật khớp của BTC; abstain dưới ngưỡng τ.
4. Formatter tất định; ghi đáp án theo từng nhóm DN; ngân sách thời gian (luật 8).

Test đầu-cuối không GPU (`tests/test_agent_local.py`, FakeEngine): đúng 3/3, bắt được compile sai (trạng thái chưa ánh xạ) và sửa, chạy đúng vòng sửa lỗi và vòng tự kiểm tra; nhánh hết thời gian cho abstain đủ dòng.

3. Kết quả thực nghiệm (tích cực và tiêu cực)

E2b public test (Qwen3-14B-AWQ, 4×L4, `--compile --k 4 --kc 4`; 746/1000 câu có log vì 1/4 shard chết; không có đáp án nên không có PA):

Đo	Giá trị	Ý nghĩa
Mẫu chạy thành công sau sửa lỗi	2787/2984 (93 %); lần đầu 2372 (79 %)	vòng sửa lỗi có ích (+14 điểm %)
Tỷ lệ phiếu của đáp án đầu	4/4: 150 câu (20 %); 3/4: 183; 2/4: 342 (46 %); 1/4: 69	**độ nhất quán thấp** → nhiều câu có thể sai; τ = 0.5 có thể quá dễ dãi
Compile thành công	5/40 ứng viên; 3/14 DN có bảng chuẩn	**tiêu cực**: bước compile quá khó với 14B ở dạng hiện tại
Vòng tự kiểm tra (kết quả 0/rỗng)	246 lần	cần đo xem có cải thiện không (chưa có đáp án)
Thông lượng	110–170 token/s mỗi L4 (kỳ vọng ≥ 1,500)	**tiêu cực**: prefix cache bị đẩy ra liên tục (đã sửa, chưa đo lại)

E2b train — điểm PA đầu tiên trên đáp án thật (150/300 câu: shard 1 và 3 xong; shard 2 chết vì prompt quá dài; shard 0 treo tới khi kernel hết 12 giờ; code cũ: còn lỗi `1,134tr`, chưa sinh theo nhóm prefix). Phân tích: `python3 src/analyze.py <logs> data/raw/train/train/answers.jsonl`.

Đo	Giá trị
PA (τ = 0.5)	**−0.14** (57 đúng, 78 sai, 15 abstain)
Độ chính xác từng mẫu riêng lẻ	nhánh A 30 %, nhánh B 37–41 %
Đúng theo tỷ lệ phiếu	4/4: 65 % (60 câu); 3/4: 23 %; 2/4: 24 %; 1/4: 17 %
PA nếu chỉ trả lời khi 4/4 (τ = 1.0, trong mẫu)	+0.12
Theo type	number −0.10 (97 câu), percent 0.00, list −0.83, string −0.71, date +0.45

Kết luận: - (1) Độ chính xác từng chương trình (~37 %) là nút thắt; voting chỉ đáng tin khi đồng thuận tuyệt đối. - (2) τ phải cao (≥ 1.0 với K = 4) cho tới khi độ chính xác tăng. - (3) Lỗi ngữ nghĩa lặp lại, sửa được bằng prompt/helper tổng quát: - **khách lẻ bị tính là khách** (`"Khách l□"`, `"l□"`, `"kl"` trong top khách hàng); - trả `"Gi□m 1.79%"` (string) thay vì percent `-1.79`; - trả table khi câu hỏi cần list; - đếm dòng thay vì đơn (147 so với 59); - doanh thu không lọc ngày (5.37 tỷ so với 8.1 triệu); - số đơn huỷ sai (170 so với 61). - (4) Lỗi chương trình hàng đầu: sai tên cột (`'Thời gian'` 59, `'Ngày bán'` 21), ngày ngoài phạm vi.

E2c public test (code mới nhất: bảo vệ độ dài prompt, sinh theo nhóm prefix, chép model cục bộ; 1000/1000 câu):

Đo	E2b	E2c
Câu có log	746 (1 shard chết)	**1000**
Nạp model (4 tiến trình)	1320 s	**230 s**
Thông lượng vòng trả lời đầu, mỗi L4	110–173 tok/s	176–234 tok/s (chỉ +30 %, vẫn thấp hơn kỳ vọng nhiều lần)
Thông lượng compile	53–110 tok/s	21–57 tok/s (sinh theo nhóm prefix → mỗi lần gọi chỉ 4 chuỗi)
Mẫu chạy được (lần đầu / sau sửa)	79 % / 93 %	81 % / 95 %
Tỷ lệ phiếu đáp án đầu 4/4, 3/4, 2/4, ≤ 1/4	20 / 25 / 46 / 9 %	26 / 21 / 45 / 8 %

Đo	E2b	E2c
Compile có bảng chuẩn	3/14 DN	3/14 DN (dev_002, dev_003, dev_009)
Đáp án cuối: abstain / unanswerable	71 / 12 (trên 746)	78 / 14

Lỗi chương trình hàng đầu ở E2c giống E2b: ngày ngoài phạm vi (231), sai tên cột (70), `.str` (68), không gán `ANSWER` (64), đọc file `orders.pkl` (29).

Lỗi chương trình phổ biến nhất (E2b):

Lỗi	Số lần
`.str` trên cột không phải chuỗi	101
tạo ngày không tồn tại (`2026-02-29`, "day is out of range")	~165
tự đọc file `orders.csv` dù đã được dặn	52
không gán `ANSWER`	51
sai tên cột	33

Đây là mục tiêu cải tiến trực tiếp: helper ngày an toàn, nhắc `.astype(str)`, chặn đọc file.

Hạ tầng (kết quả âm):

- Qwen3.5-9B không khởi tạo được trên T4.
- 14B-AWQ trên một T4 không đủ KV cho prompt ~16k (DP trên T4 không dùng được).
- FlashInfer sampler JIT hỏng trên L4.
- Chi tiết ở PDF 2.

4. Hạn chế và điều kiện kiểm chứng

- PA duy nhất đo được: **−0.14 trên 150 câu train** (E2b, code cũ, chỉ 15 DN). Cỡ mẫu nhỏ và code có lỗi đã biết; phải đo lại bằng code mới trên toàn bộ train (dev / holdout).
- Ngưỡng τ, tỷ lệ K giữa hai nhánh, có giữ compile hay không phải chọn trên DN dev (`biz_101`–`biz_120`) và báo cáo trên holdout (`biz_121`–`biz_130`); public chỉ để đối chiếu.
- Bộ làm sạch được phát triển nhìn cả train và public (audit chạy trên cả hai); bộ test tổng hợp là bằng chứng độc lập duy nhất cho tính tổng quát.
- Chưa chạy thử Docker trên GPU Blackwell; tất định ($|\Delta PA| \leq 0.03$) chưa đo.