01 — Scientific Findings (DataMate, Zalo AI Challenge 2026)

Bàn giao ngày 2026-10-30 (branch `datamate`, repo `lhaochen118-ship-it/ZC`). Tài liệu này nêu đóng góp, ý nghĩa, kết quả tích cực và tiêu cực, bằng chứng và điều kiện kiểm chứng. Chưa có điểm PA nào đo được trên dữ liệu có đáp án (các run có đáp án vẫn đang chạy lúc bàn giao, xem `RUNNING_KERNELS.md`).

1. Bài toán và hệ quả của thước đo

- Agent trả lời câu hỏi tiếng Việt đời thường trên dữ liệu bảng bẩn (CSV/Excel/SQLite) của hộ kinh doanh nhỏ, hoặc trả `unanswerable` / `abstain`. Điểm là **Penalized Accuracy**: đúng +1, abstain 0, sai −1.
- **Hệ quả quyết định:** trả lời khi và chỉ khi xác suất đúng ước lượng > 0.5. Mọi thiết kế phải có ước lượng xác suất đúng có hiệu chuẩn; hiện dùng **tỷ lệ phiếu** của K chương trình độc lập làm ước lượng.
- Train 3,000 câu / 30 DN (có đáp án), public 1,000 / 14 DN. Train: number 63 %, percent 19 %, list 6 %, date 5 %, string 3 %, unanswerable 2.3 %, boolean, table < 1 %. Khoảng 40 % câu là doanh thu.
- **Rulebook khác nhau giữa các split** (public thêm định nghĩa mới), private test có ngành mới → hệ thống phải đọc rulebook và README lúc chạy; không thể mã hoá cứng luật của train.

2. Đóng góp đã kiểm chứng

2.1 Bộ làm sạch tổng quát (`src/ingest.py`)

Chỉ dựa trên quy ước chung, không theo tên DN / cột / file cụ thể:

- dò dòng header (mật độ ô chữ), bỏ header lặp và dòng "Tổng…/Ghi chú…";
- ghép header 2 tầng có tên con trùng;
- số kiểu Việt và kiểu Mỹ: `10.000đ`, `105k`, `1tr440`, `1,134tr`, `531 500`, `VND 1,234`, `(1.000)`, `12,5%`, `1 bao 25kg` (giá trị + cột đơn vị `__unit`);
- quy ước dấu thập phân suy theo **từng cột**, chỉ dùng cho giá trị mơ hồ kiểu `1.500`; cột tiền giữ quy tắc theo từng giá trị;
- ngày: `dd/mm/yyyy`, ISO, `1 thg 6 2025`, `Ngày 1 tháng 6 năm 2025`, serial Excel (cả dạng chuỗi trong cột ngày), `dd/mm` + năm lấy từ tên sheet / file / dòng tiêu đề;
- mã (số 0 đầu, IMEI, ≥ 12 chữ số) và địa chỉ giữ dạng chữ;
- gộp các file / sheet của cùng một danh sách.

Bằng chứng	Kết quả
Audit "cột chỉ đọc được một phần" trên dữ liệu thật	78 → **0** (train); public còn 2 cột IMEI, đúng là chữ
Bộ test tổng hợp `tests/test_ingest_robust.py`: 12 biến thể bẩn không lấy từ dữ liệu thi	**12/12** khôi phục đúng giá trị
So từng giá trị giữa 2 phiên bản cache trên 44 DN	phát hiện lỗi `1,134tr` → **1,134 tỷ** (đúng: 1.134 triệu) ở 13 DN; sau sửa chỉ còn đúng các thay đổi mong muốn
3 chương trình viết tay trên bảng đã làm sạch (`biz_101`)	**khớp tuyệt đối** đáp án BTC (số đơn hôm qua, doanh thu hôm nay, ngày doanh thu cao nhất tháng)

Ý nghĩa: lớp dữ liệu đủ để ra đáp án chính xác tuyệt đối; sai số còn lại nằm ở bước sinh chương trình.

2.2 Bộ chấm cục bộ đúng luật BTC (`src/score.py`)

Chuẩn hoá chuỗi (NFC, lowercase, bỏ dấu câu, giữ dấu tiếng Việt), alias theo phần tử / theo dòng, list có thứ tự, table so cột theo tên rồi theo vị trí, hàng như tập hợp, số phải là JSON number.

- Chấm đáp án chuẩn với chính nó: PA = 1.0 (3000/3000).
- 167/167 câu trả lời bằng alias / mã được chấm đúng.
- Số ghi dạng chuỗi bị chấm sai, đúng rulebook §9.

2.3 Kiến trúc agent (`src/agent.py`), mới kiểm chứng ở mức đường ống

1. **Compile** (một lần mỗi DN): LLM viết chương trình dựng bảng chuẩn `C` (orders / lines / items / purchases / payments + NOTES về thông tin không có). Kiểm tra schema; lỗi được gửi lại để sửa. Chọn ứng viên có chữ

ký tháng đồng thuận nhất.

2. **Answer**: K chương trình mỗi câu chia hai nhánh (A dùng `C`, B dùng bảng làm sạch `T`); sửa lỗi theo traceback; tự kiểm tra khi kết quả 0 / rỗng.
3. **Vote** theo đúng luật khớp của BTC; abstain dưới ngưỡng τ.
4. Formatter tất định; ghi đáp án theo từng nhóm DN; ngân sách thời gian (luật 8).

Test đầu-cuối không GPU (`tests/test_agent_local.py`, FakeEngine): đúng 3/3, bắt được compile sai (trạng thái chưa ánh xạ) và sửa, chạy đúng vòng sửa lỗi và vòng tự kiểm tra; nhánh hết thời gian cho abstain đủ dòng.

3. Kết quả thực nghiệm (tích cực và tiêu cực)

E2b public test (Qwen3-14B-AWQ, 4×L4, `--compile --k 4 --kc 4`; 746/1000 câu có log vì 1/4 shard chết; không có đáp án nên không có PA):

Đo	Giá trị	Ý nghĩa
Mẫu chạy thành công sau sửa lỗi	2787/2984 (93 %); lần đầu 2372 (79 %)	vòng sửa lỗi có ích (+14 điểm %)
Tỷ lệ phiếu của đáp án đầu	4/4: 150 câu (20 %); 3/4: 183; 2/4: 342 (46 %); 1/4: 69	**độ nhất quán thấp** → nhiều câu có thể sai; τ = 0.5 có thể quá dễ dãi
Compile thành công	5/40 ứng viên; 3/14 DN có bảng chuẩn	**tiêu cực**: bước compile quá khó với 14B ở dạng hiện tại
Vòng tự kiểm tra (kết quả 0/rỗng)	246 lần	cần đo xem có cải thiện không (chưa có đáp án)
Thông lượng	110–170 token/s mỗi L4 (kỳ vọng ≥ 1,500)	**tiêu cực**: prefix cache bị đẩy ra liên tục (đã sửa, chưa đo lại)

E2c public test (code mới nhất: bảo vệ độ dài prompt, sinh theo nhóm prefix, chép model cục bộ; 1000/1000 câu):

Đo	E2b	E2c
Câu có log	746 (1 shard chết)	**1000**
Nạp model (4 tiến trình)	1320 s	**230 s**
Thông lượng vòng trả lời đầu, mỗi L4	110–173 tok/s	176–234 tok/s (chỉ +30 %, vẫn thấp hơn kỳ vọng nhiều lần)
Thông lượng compile	53–110 tok/s	21–57 tok/s (sinh theo nhóm prefix → mỗi lần gọi chỉ 4 chuỗi)
Mẫu chạy được (lần đầu / sau sửa)	79 % / 93 %	81 % / 95 %
Tỷ lệ phiếu đáp án đầu 4/4, 3/4, 2/4, ≤ 1/4	20 / 25 / 46 / 9 %	26 / 21 / 45 / 8 %
Compile có bảng chuẩn	3/14 DN	3/14 DN (dev_002, dev_003, dev_009)
Đáp án cuối: abstain / unanswerable	71 / 12 (trên 746)	78 / 14

Lỗi chương trình hàng đầu ở E2c giống E2b: ngày ngoài phạm vi (231), sai tên cột (70), `.str` (68), không gán `ANSWER` (64), đọc file `orders.pkl` (29).

Lỗi chương trình phổ biến nhất (E2b):

Lỗi	Số lần
`.str` trên cột không phải chuỗi	101
tạo ngày không tồn tại (`2026-02-29`, "day is out of range")	~165
tự đọc file `orders.csv` dù đã được dặn	52
không gán `ANSWER`	51
sai tên cột	33

Đây là mục tiêu cải tiến trực tiếp: helper ngày an toàn, nhắc `.astype(str)`, chặn đọc file.

Hạ tầng (kết quả âm):

- Qwen3.5-9B không khởi tạo được trên T4.
- 14B-AWQ trên một T4 không đủ KV cho prompt ~16k (DP trên T4 không dùng được).
- FlashInfer sampler JIT hỏng trên L4.
- Chi tiết ở PDF 2.

4. Hạn chế và điều kiện kiểm chứng

- **Chưa có PA trên train** cho bất kỳ cấu hình LLM nào. Mọi kết luận về độ chính xác đang chờ e1b / e1c / e2b (`RUNNING_KERNELS.md`); e1b, e1c, e2b dùng code cũ còn lỗi (xem bảng ở đó), nên số của chúng là cận dưới.
- Ngưỡng τ, tỷ lệ K giữa hai nhánh, có giữ compile hay không phải chọn trên DN dev (`biz_101`–`biz_120`) và báo cáo trên holdout (`biz_121`–`biz_130`); public chỉ để đối chiếu.
- Bộ làm sạch được phát triển nhìn cả train và public (audit chạy trên cả hai); bộ test tổng hợp là bằng chứng độc lập duy nhất cho tính tổng quát.
- Chưa chạy thử Docker trên GPU Blackwell; tất định ($|\Delta PA| \leq 0.03$) chưa đo.