03 — Handoff (DataMate, khung chat mới)

Bàn giao 2026-10-30 16:45 UTC. Repo `lhaochen118-ship-it/ZC`, branch `datamate` (là bản sao của `hmm-navigation-2` trong `hmm-develop`, giữ lịch sử; nội dung HMM đã bỏ, khôi phục được bằng `git checkout de4360e -- <path>`). Không tạo PR.

1. Bối cảnh

- **Cuộc thi:** Zalo AI Challenge 2026, track DataMate (đề đầy đủ: `docs/00_TASK.md`).
- **Mục tiêu:** tối đa Penalized Accuracy trên private test, chạy offline ≤ 6 giờ trên 2 × RTX 5090, ≤ 15 B tham số, tất định (|ΔPA| ≤ 0.03).
- **Hạn:**
- nộp Docker **16/11 23:59 (GMT+7)**;
- private test 20–23/11.
- **Public LB:** tối đa 5 lần nộp/ngày, do user nộp tay trên portal.

User chốt

- Tự động hoá tối đa, không hỏi lại quyết định nghiên cứu thông thường.
- **Chỉ tạo file nộp thử khi kết quả tốt.**
- Bộ làm sạch phải tổng quát, không vá cứng theo case của dataset.
- Dùng mọi acc Kaggle; mỗi acc dùng đủ 2 phiên GPU; L4 trước, T4 sau.
- Kẹt hàng đợi 5 phút thì huỷ và đẩy lại (≤ 4 lần).
- Định kỳ dọn tiến trình treo hoặc thừa.
- Lưu kết quả dùng lại được thành dataset/output public của `nhatlong1103`.
- Theo dõi bằng watcher nền thay vì tự kiểm tra.
- Tìm thông tin chỉ đọc văn bản/paper, không đọc code repo của người khác.

2. Trạng thái

Hạng mục	Trạng thái
Đề, dữ liệu, bộ chấm	Xong. Dữ liệu: Kaggle `nhatlong1103/zc-2026` (public) → `data/raw/`
Bộ làm sạch	Xong, đã kiểm chứng (audit 0 cột lỗi, 12/12 biến thể tổng hợp, chương trình viết tay khớp tuyệt đối)
Agent v1	Compile + 2 nhánh + sửa lỗi + tự kiểm tra + vote + ngân sách thời gian + DP. Test không GPU: đạt
Hạ tầng Kaggle	fanout / make_kernel / run_kernel / watch_done; assets offline public; L4 đã xác nhận
Đo độ chính xác	**Chưa có PA nào.** 3 kernel train/baseline còn chạy (`handoff/RUNNING_KERNELS.md`); E2c public xong (không có đáp án)
Fine-tune	`harvest.py`, `train_sft.py` viết xong, chưa chạy
Docker	File xong (`docker/`, hướng dẫn `docker/SETUP_DOCKER.md`); user sẽ build trên máy mình; chưa có Docker guideline của BTC

3. Việc tiếp theo (theo thứ tự)

Bước 0 — Khởi động (khoảng 10 phút)

1. Xin user token của các acc: `nguyenhoa99`, `mxuanquy`, `anderson1202`, `nhatlong1103` (và `yuan1103` khi quota reset). - Lưu vào `~/.kaggle/tok_<acc>` (chmod 600) và kiểm tra bằng `kaggle competitions list`.
2. Cài gói: `bash pip install kaggle markdown xhtml2pdf tokenizers python-calamine`
3. Tải dữ liệu: `bash kaggle datasets download nhatlong1103/zc-2026 -p data/raw --unzip`

4. Chạy test không GPU, cả hai phải PASS: `bash python3 tests/test_ingest_robust.py` `bash python3 tests/test_agent_local.py data/raw/train/train <scratch>`
5. Kéo kết quả các kernel còn chạy, rồi phân tích từng run train bằng `src/analyze.py` (xem `RUNNING_KERNELS.md`): `bash python3 automation/pull_kernels.py <scratch>/pulled`

Bước 1 — Khắc phục hết lỗi đã mắc (user yêu cầu)

Từ `01_SCIENTIFIC_FINDINGS.md` §3 và `02_ENGINEERING_OPS_NOTES.md` §5:

1. **Lỗi chương trình phổ biến:** - Thêm helper ngày an toàn vào namespace: cộng/trừ tháng có kẹp ngày cuối tháng, cùng kỳ tháng trước theo rulebook, khoảng tuần. Hiện ~165 lỗi `day is out of range`. - Chặn đọc file: thay `open` / `pd.read_*` trong sandbox bằng hàm báo "bảng đã có trong T". Hiện 52 lỗi. - Nhắc dùng `.astype(str)` trước `.str` (101 lỗi). - Kiểm tên cột bằng `match_names` (33 lỗi). - Nếu chương trình không gán `ANSWER` (51 lỗi), gợi ý trong vòng sửa.
2. **Compile chỉ 5/40 thành công:** - So A/B trên train: có compile so với không compile (`--paths BBBB`). - Nếu compile không giúp thì bỏ, hoặc rút gọn schema chỉ còn `orders` + `lines`.
3. **Độ đồng thuận thấp** (46 % câu chỉ 2/4 phiếu): - Chọn τ trên DN dev bằng `analyze.py`. - Thử "leo thang": chỉ câu đồng thuận ≤ 0.5 mới sinh thêm mẫu hoặc bật `--think`.
4. **Thông lượng** (E2c: chép model cục bộ hiệu quả, 230 s; sinh theo nhóm prefix chỉ +30 %, compile còn chậm hơn): - gộp nhiều nhóm prefix vào một lần gọi trong giới hạn KV; - đo tốc độ decode từng chuỗi; - thử `kv_cache_dtype=fp8`, `max_num_seqs`.

Mục tiêu ≥ 1,000 token/s mỗi L4. 5. **Mọi cấu hình mới:** chạy thử nhỏ trên đúng loại GPU trước (`--subset 8`, 1 phiên), rồi mới chạy full.

Bước 2 — Chạy lại trên GPU đã cấp

Phiên	Việc
`nguyenhoa99` (2 × 4 L4)	toàn bộ 3,000 câu train, chia 2 kernel theo DN (dev / holdout). Cho PA theo type, chọn τ, và dữ liệu cho `harvest.py`
`mxuanquy`, `anderson1202` (T4, `--tp 2`)	các biến thể A/B nhỏ (300 câu)
Sau đó	public test chỉ khi PA holdout tốt; user quyết định nộp

Bước 3 — Sau đó

- **E7:** `harvest.py` → `train_sft.py` trên L4 (bf16 gắn bằng `--ms qwen-lm/qwen-3/transformers/14b/1`, wheel `bitsandbytes` từ `nhatlong1103/zc-train-wheels`) → `agent --lora`.
- So Qwen3-14B-FP8 với AWQ trên L4 (bản nộp dự kiến dùng FP8 trên RTX 5090).
- Ước lượng thời gian private test (cỡ ~1000–2000 câu) trên 2 × 5090.
- Docker: chờ guideline của BTC; nhận kết quả chạy thử từ user (`docker/SETUP_DOCKER.md`).