03 — Handoff (DataMate, sang khung chat 3)

Bàn giao 2026-10-31 04:45 UTC (cuối khung chat 2). User yêu cầu: chờ các kernel đang chạy xong rồi dừng, không khởi chạy thêm gì trong khung chat 2. - Repo `lhaochen118-ship-it/ZC`, branch làm việc `claude/peaceful-carson-0dny90` (tiếp nối `datamate`). Không tạo PR. - Kết quả và bằng chứng: PDF 1. Vận hành và lỗi: PDF 2. File này chỉ có mục tiêu, trạng thái, quyết định, vị trí, việc tiếp theo.

1. Mục tiêu

- **Cuộc thi:** Zalo AI Challenge 2026, track DataMate (đề: `docs/00_TASK.md`).
- **Mục tiêu:** tối đa Penalized Accuracy trên private test, trong các ràng buộc:
- offline, ≤ 15 B tham số;
- ≤ 6 giờ trên 2 × RTX 5090;
- tất định (|ΔPA| ≤ 0.03).
- **Hạn:**
- nộp Docker **16/11 23:59 GMT+7**;
- private test 20–23/11.
- **Public LB:** ≤ 5 lần nộp/ngày, user nộp tay.

2. Quyết định user đã chốt (giữ nguyên)

- **Tự chủ:** tự động hoá tối đa, không hỏi lại quyết định nghiên cứu thông thường. Vòng lặp: hiểu → đề xuất → chạy → chấm → cải tiến.
- **Nộp bài:** chỉ tạo file nộp khi kết quả tốt; user quyết định nộp.
- **Tính tổng quát:** bộ làm sạch / helper phải tổng quát, không vá cứng theo DN của dataset.
- **Kaggle:**
- dùng mọi acc; mỗi acc đủ 2 phiên GPU; L4 trước, T4 sau;
- QUEUED > 5 phút (L4) / 10 phút (T4) → huỷ và đẩy lại, tối đa 4 lần;
- định kỳ dọn tiến trình treo; không tự ngắt được thì báo user.
- **Bảo mật token:** token chỉ ở `~/.kaggle`; `nhatlong1103` chỉ để đăng dataset (không chạy kernel).
- **Theo dõi:** bằng watcher nền, không tự kiểm tra định kỳ.
- **Tìm thông tin:** chỉ đọc văn bản / paper, không đọc code repo của người khác.
- **Ngắt kernel:** user không tự ngắt được kernel; agent phải tự tìm cách (`kaggle kernels delete -y`, từng lệnh một).

3. Trạng thái

Hạng mục	Trạng thái
Làm sạch (`ingest.py`) + lớp ngữ nghĩa (`semantic.py`)	Xong, đã kiểm chứng
Agent	Cấu hình tốt nhất (mục 5) đạt **PA train dev +0.47 / holdout +0.44** (3000 câu, leave-business-out); thêm thinking: holdout +0.51 vs +0.25 (354 câu, e11)
Thư viện shots	v4: 4228 chương trình (`src/shots/train_shots.jsonl`)
Public test	Run `p1` (cấu hình tốt nhất, shots v2, **trước** SafePool) đang chạy > 7.5 giờ (nghi kẹt); chưa có file nộp
Thinking	**Có lợi trên holdout:** e11 (code mới nhất + shots v4 + think) PA +0.51 vs e8 +0.25 trên cùng 354 câu holdout; dev e10l +0.69 vs +0.59. Chậm ≈ 2.5–3×. Chưa tách riêng phần của thinking
Sửa chưa đo trên GPU	khoảng ngày dữ liệu → unanswerable; NOTES compile không gọi bảng T là thiếu; `SafePool`; gợi ý `time=` trong compile
Docker	`docker/predict.sh` đã dùng cấu hình tốt nhất; chưa build / chưa chạy thử; chưa có guideline BTC

Hạng mục	Trạng thái
FP8 cho 5090, tất định, thời gian thật	Chưa làm

Kernel còn chạy: `handoff/RUNNING_KERNELS.md`. Kéo kết quả:

```
python3 automation/pull_kernels.py <scratch>/pulled
```

4. Vị trí

Thứ	Ở đâu
Dữ liệu BTC	Kaggle `nhatlong1103/zc-2026` → `data/raw/` (không commit)
Mã	`src/` (agent, ingest, semantic, vnnorm, score, compare, analyze, build_shots, harvest, train_sft, run_kaggle); `automation/` (Kaggle); `tests/`; `docker/`
Assets offline	output kernel `nhatlong1103/zc-assets` (wheels vLLM 0.32 + Qwen3-14B-AWQ, `--ks`); FP8: dataset `nhatlong1103/zc-m-qwen3-14b-fp8`
Log mọi run khung chat 2	`results/chat2_runs/<run>__<kernel>/*.jsonl.gz` (README trong đó)
Nhật ký thí nghiệm	`EXPERIMENT_LOG.md` entry 3–5
Token	`~/.kaggle/tok_<acc>` (container cũ; khung chat mới **xin lại user**)

5. Cấu hình tốt nhất (tái lập)

```
python3 automation/fanout.py <runs>/<run> zc-<run> "run_kaggle.py <train|public_test> OUT --model Qwen/Qwen3-
```

τ = 0.5 (mặc định). **Khuyến nghị mới (sau e11): thêm** `--think --max-tokens 8192` (holdout +0.51 vs +0.25), kèm `--budget` để không quá 6 giờ; cấu hình không think là phương án dự phòng nếu thời gian thật trên 2×5090 không đủ.

6. Việc tiếp theo (theo thứ tự)

1. **Khởi động:** - xin token, kiểm bằng `kaggle competitions list`; - tải dữ liệu, chạy 2 test không GPU; - kéo kết quả `p1`, `e11` (`pull_kernels.py`; nếu khung chat 2 đã kéo thì log nằm trong `results/chat2_runs/`); - kernel nào còn RUNNING quá 12 giờ kể từ lúc đẩy (`RUNNING_KERNELS.md`) thì coi là kẹt: ngắt bằng `kaggle kernels delete -y`.
2. **File nộp public:** - khi `p1` xong: kiểm đủ 1000 dòng, đúng định dạng; - chép `submission.jsonl` vào `results/p1_submission.jsonl`; - báo user kèm ước lượng PA train (+0.44 holdout); user quyết định nộp; - nếu `p1` kẹt / hỏng: chạy lại public test với cấu hình mục 5 và code mới nhất (có SafePool), chia 2 kernel theo DN (`--biz`) để mỗi kernel ≤ ~500 câu.
3. **Đo các sửa chưa đo:** chạy cấu hình mục 5 (code mới nhất + shots v4) trên 4 DN của e7 (114, 116, 117, 125) và 4 DN của e6a (105, 108, 115, 118); so cặp bằng `src/compare.py` với log trong `results/chat2_runs/`.
4. **Thinking (e11 đã xác nhận có lợi trên holdout):** tách riêng phần của thinking (chạy code mới nhất + shots v4 **không** think trên cùng biz_121/124/129, so với e11), rồi: - đo thời gian; - cân nhắc chỉ bật think cho câu đồng thuận thấp (leo thang: chạy lần 2 với `--think` cho câu conf < 0.75).
5. **Giảm lỗi còn lại** (PDF 1 §6): - unanswerable; - `qty_base` / xếp hạng; - tuần / ca; - câu kho đơn vị lớn.

Mỗi sửa: tìm trong log → sửa ở `semantic.py` / thông báo lỗi trước, prompt sau. 6. **Mở rộng shots:** sau mỗi run train, `build_shots.py` gộp mọi log (gồm `results/chat2_runs`) → commit `src/shots/`. 7. **Chuẩn bị nộp cuối:** - Qwen3-14B-FP8 (5090, Blackwell): chạy thử TP=2 trên L4 hoặc mượn GPU lớn; - kiểm tất định: chạy 2 lần cùng cấu hình, |ΔPA| ≤ 0.03; - ước lượng 6 giờ (`--budget`); - Docker build theo `docker/SETUP_DOCKER.md` (user build trên máy mình).

Quota: phần lớn acc hết quota tuần (PDF 2 §2.1). Quota reset theo tuần; probe lại bằng kernel nhỏ trước khi lên lịch.